

Modelos de Series de Tiempo: (S)ARIMA y SARIMAX

Análisis, Identificación, Estimación y
Diagnóstico de Modelos Estacionales

Nina Guevara

Finanzas Cuantitativas
Universidad Panamericana
April 16, 2026

Contents

1	Introducción a las Series de Tiempo	1
2	El Modelo ARIMA	1
2.1	Componentes básicos	1
2.1.1	Proceso Autoregresivo AR(p)	1
2.1.2	Proceso de Media Móvil MA(q)	2
2.1.3	Proceso ARMA(p,q)	2
2.1.4	Proceso ARIMA(p,d,q)	2
3	El Modelo SARIMA	2
3.1	Notación y estructura general	2
3.2	Descripción de cada parámetro	3
3.3	Herramientas de identificación: ACF y PACF	3
4	El Principio de Parsimonia	4
4.1	Criterios de selección de modelos	5
4.2	Test de Ljung-Box	5
5	Base de Datos: Pasajeros Aéreos Internacionales	6
5.1	Descripción del conjunto de datos	6
5.2	Datos mensuales 1949–1950	6
5.3	Representación gráfica de la serie	7
5.4	Modelo identificado: SARIMA(0, 1, 1)(0, 1, 1) ₁₂	7
6	El Modelo SARIMAX	8
6.1	Definición y motivación	8
6.2	Base de datos: Ventas de helados con variables exógenas	9
6.3	Figura: Estacionalidad de ventas de helados	10
6.4	¿Cuándo usar SARIMAX vs. SARIMA?	10
7	Proceso de Modelación: Metodología Box-Jenkins	10
8	Resumen de Criterios y Fórmulas Clave	11
9	Conclusiones	11

1 Introducción a las Series de Tiempo

Una **serie de tiempo** es una sucesión de observaciones de una variable aleatoria indexadas en el tiempo:

$$\{Y_t\}_{t=1}^T, \quad t = 1, 2, \dots, T$$

El objetivo central del análisis de series de tiempo en finanzas cuantitativas es doble: *entender la estructura dinámica* del proceso generador de datos y *realizar pronósticos* fuera de muestra. Los modelos de la familia ARIMA (Box y Jenkins, 1976) constituyen el estándar de referencia para series univariadas, mientras que su extensión estacional, SARIMA, permite capturar ciclos periódicos presentes en datos financieros y económicos como ventas mensuales, rendimientos trimestrales o indicadores macroeconómicos.

Conceptos previos fundamentales

- **Estacionariedad:** una serie $\{Y_t\}$ es (débilmente) estacionaria si $\mathbb{E}[Y_t] = \mu$, $\text{Var}(Y_t) = \sigma^2 < \infty$ y $\text{Cov}(Y_t, Y_{t-k}) = \gamma_k$ sólo depende de k , no de t .
- **Ruido blanco:** proceso $\{\varepsilon_t\}$ con $\mathbb{E}[\varepsilon_t] = 0$, $\text{Var}(\varepsilon_t) = \sigma^2$ y $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0 \forall t \neq s$.
- **Proceso integrado $I(d)$:** requiere d diferenciaciones ordinarias para volverse estacionario.

2 El Modelo ARIMA

2.1 Componentes básicos

2.1.1 Proceso Autoregresivo AR(p)

Un proceso autoregresivo de orden p modela Y_t como combinación lineal de sus p valores pasados más un error:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

Usando el operador de rezago L (donde $L^k Y_t = Y_{t-k}$), se escribe compactamente:

$$\Phi(L) Y_t = c + \varepsilon_t, \quad \Phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$$

La condición de estacionariedad exige que todas las raíces de $\Phi(z) = 0$ estén **fuera del círculo unitario**.

2.1.2 Proceso de Media Móvil MA(q)

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Todo proceso MA(q) es estacionario. La condición de *invertibilidad* requiere que las raíces de $\Theta(z) = 0$ estén fuera del círculo unitario.

2.1.3 Proceso ARMA(p,q)

Combina ambas estructuras:

$$\Phi(L) Y_t = c + \Theta(L) \varepsilon_t$$

2.1.4 Proceso ARIMA(p,d,q)

Cuando la serie no es estacionaria se aplica diferenciación ordinaria:

$$\nabla^d Y_t = (1 - L)^d Y_t$$

El modelo ARIMA(p,d,q) aplica ARMA(p,q) sobre $\nabla^d Y_t$:

$$\Phi(L) (1 - L)^d Y_t = c + \Theta(L) \varepsilon_t$$

3 El Modelo SARIMA

3.1 Notación y estructura general

La presencia de estacionalidad — variaciones que se repiten con período s — exige incorporar operadores estacionales. La notación completa es:

$$\text{SARIMA}(p, d, q) \times (P, D, Q)_s$$

donde la ecuación del modelo es:

$$\Phi_p(L) \tilde{\Phi}_P(L^s) \nabla^d \nabla_s^D Y_t = c + \Theta_q(L) \tilde{\Theta}_Q(L^s) \varepsilon_t$$

con los operadores:

$$\nabla_s^D Y_t = (1 - L^s)^D Y_t, \quad \tilde{\Phi}_P(L^s) = 1 - \Phi_1 L^s - \cdots - \Phi_P L^{sP}$$

3.2 Descripción de cada parámetro

La Tabla 1 resume los siete parámetros del modelo SARIMA.

Table 1: Parámetros del modelo SARIMA(p, d, q)(P, D, Q) $_s$

Parámetro	Tipo	Descripción	Identificación
p	No estacional	Orden autoregresivo ordinario. Número de rezagos de Y_t que se incluyen en la ecuación.	PACF
d	No estacional	Grado de integración ordinario. Número de diferencias $(1 - L)^d$ para lograr estacionariedad.	Prueba ADF / KPSS
q	No estacional	Orden de media móvil ordinario. Número de errores pasados ε_{t-k} en el modelo.	ACF
P	Estacional	Orden autoregresivo estacional. Actúa en rezagos múltiplos de s : $s, 2s, 3s, \dots$	PACF estacional
D	Estacional	Diferenciación estacional. Aplica $(1 - L^s)^D$ para eliminar tendencia periódica.	Prueba CH
Q	Estacional	Orden de media móvil estacional. Errores en rezagos $s, 2s, \dots$	ACF estacional
s	Periodo	Longitud del ciclo estacional (meses: 12; trimestres: 4; semanas: 52; días: 7).	Inspección

3.3 Herramientas de identificación: ACF y PACF

Función de Autocorrelación (ACF)

La ACF al rezago k se define como:

$$\rho_k = \frac{\text{Cov}(Y_t, Y_{t-k})}{\text{Var}(Y_t)} = \frac{\gamma_k}{\gamma_0}$$

Identifica el orden q de la componente MA: la ACF se **trunca** en el rezago q para un proceso MA puro. **Limitación crucial:** si se aplica la ACF a un proceso AR puro, ésta decae geométricamente y *no permite identificar el orden p* — tal como se señala en la sesión de clase.

Función de Autocorrelación Parcial (PACF)

La PACF al rezago k mide la correlación entre Y_t e Y_{t-k} **condicional** (esperanza condicional) a los rezagos intermedios $\{Y_{t-1}, \dots, Y_{t-k+1}\}$:

$$\alpha_k = \text{Corr}(Y_t, Y_{t-k} \mid Y_{t-1}, \dots, Y_{t-k+1})$$

Identifica el orden p de la componente AR: la PACF se **trunca** en el rezago p para un proceso AR puro.

La Tabla 2 condensa las reglas de identificación.

Table 2: Reglas de identificación mediante ACF y PACF

Proceso	ACF	PACF
AR(p)	Decae geométricamente	Se trunca en rezago p
MA(q)	Se trunca en rezago q	Decae geométricamente
ARMA(p, q)	Decae (mixto)	Decae (mixto)
SAR(P) _{s}	Picos en $s, 2s, \dots$ decaen	Pico significativo en s
SMA(Q) _{s}	Pico significativo en s	Picos en $s, 2s, \dots$ decaen

4 El Principio de Parsimonia

El **principio de parsimonia** (principio de Ockham aplicado a modelos estadísticos) establece que, entre dos modelos con ajuste equivalente, se prefiere el de menor complejidad. En SARIMA esto se formaliza como:

$$p + d + q + P + D + Q \leq C$$

donde C es una cota prefijada (usualmente $C \leq 6$). El procedimiento consiste en *variar sistemáticamente* cada grado y evaluar el modelo resultante con criterios de información y bondad de ajuste.

4.1 Criterios de selección de modelos

Table 3: Criterios de selección y diagnóstico de modelos SARIMA

Criterio	Fórmula	Interpretación	Decisión
AIC	$-2\hat{\ell} + 2k$	Penaliza el número de parámetros k . Menos restrictivo que BIC.	Minimizar
BIC	$-2\hat{\ell} + k \ln(n)$	Penaliza más fuerte: multiplica por $\ln(n)$. Favorece modelos parsimoniosos.	Minimizar
SSE	$\sum_{t=1}^T \hat{\varepsilon}_t^2$	Suma de errores al cuadrado. Mide el ajuste en muestra.	Minimizar
Log-verosimilitud	$\hat{\ell} = \log \mathcal{L}(\hat{\theta})$	Qué tan probable es observar los datos dado el modelo estimado.	Maximizar

Cuando AIC y BIC difieren en la selección del modelo, se recomienda utilizar **BIC** en muestras grandes ($n > 100$), ya que su penalización más severa reduce el riesgo de sobreajuste. En muestras pequeñas, AIC tiende a tener mejor desempeño predictivo fuera de muestra.

4.2 Test de Ljung-Box

El test de Ljung-Box verifica que los residuos del modelo estimado sean **ruido blanco**, es decir, que no quede estructura de autocorrelación sin modelar:

$$Q_{LB} = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k} \xrightarrow{H_0} \chi^2(h)$$

Table 4: Decisión con el Test de Ljung-Box

Hipótesis	Condición	Conclusión
H_0 : no hay autocorrelación	$p\text{-valor} > 0.05$	Residuos son ruido blanco ✓
H_1 : hay autocorrelación	$p\text{-valor} \leq 0.05$	Modelo mal especificado, revisar órdenes

5 Base de Datos: Pasajeros Aéreos Internacionales

5.1 Descripción del conjunto de datos

La serie clásica de Box y Jenkins (1976) registra el número mensual de pasajeros aéreos internacionales (en miles) entre enero de 1949 y diciembre de 1960. Con $n = 144$ observaciones, exhibe dos características que la hacen ideal para ilustrar SARIMA:

1. **Tendencia creciente:** la media aumenta con el tiempo $\Rightarrow$ no estacionaria, requiere $d = 1$.
2. **Heterocedasticidad estacional:** la amplitud de las oscilaciones crece con el nivel $\Rightarrow$ se aplica transformación logarítmica antes de diferenciar.

5.2 Datos mensuales 1949–1950

Table 5: Serie de pasajeros aéreos internacionales — primeros 24 meses

Fecha	Mes	Pasaj. (miles)	$\ln(\text{Pas.})$	Fecha	Mes	Pasaj. (miles)	$\ln(\text{Pas.})$
1949-01	Ene	112	4.718	1950-01	Ene	115	4.745
1949-02	Feb	118	4.771	1950-02	Feb	126	4.836
1949-03	Mar	132	4.883	1950-03	Mar	141	4.949
1949-04	Abr	129	4.860	1950-04	Abr	135	4.905
1949-05	May	121	4.796	1950-05	May	125	4.828
1949-06	Jun	135	4.905	1950-06	Jun	149	5.003
1949-07	Jul	148	4.997	1950-07	Jul	170	5.136
1949-08	Ago	148	4.997	1950-08	Ago	170	5.136
1949-09	Sep	136	4.913	1950-09	Sep	158	5.063
1949-10	Oct	119	4.779	1950-10	Oct	133	4.890
1949-11	Nov	104	4.644	1950-11	Nov	114	4.736
1949-12	Dic	118	4.771	1950-12	Dic	140	4.942

5.3 Representación gráfica de la serie




Figure 1: Serie original con tendencia creciente y estacionalidad multiplicativa. Se observa que la amplitud de las oscilaciones aumenta con el nivel de la serie, indicando heterocedasticidad estacional.




Figure 2: Serie transformada $\ln(Y_t)$. La transformación logarítmica estabiliza la varianza, convirtiendo una estacionalidad multiplicativa en aditiva. La tendencia lineal persiste: se requiere $d = 1$.

5.4 Modelo identificado: $\text{SARIMA}(0, 1, 1)(0, 1, 1)_{12}$

Conocido como el **modelo de aerolíneas** de Box-Jenkins, el modelo para $W_t = \ln(Y_t)$ es:

$$(1 - L)(1 - L^{12})W_t = (1 + \theta_1 L)(1 + \Theta_1 L^{12})\varepsilon_t$$

Table 6: Estimación del modelo SARIMA(0, 1, 1)(0, 1, 1)₁₂ — Serie de pasajeros

Parámetro	Estimado	Error est.	<i>z</i> -valor	<i>p</i> -valor
θ_1 (MA no estacional)	−0.4018	0.0896	−4.48	< 0.001
Θ_1 (MA estacional)	−0.5569	0.0731	−7.62	< 0.001
$AIC = -244.97 \quad BIC = -239.25 \quad \sigma^2 = 0.001348 \quad \text{Ljung-Box } p > 0.05$				

6 El Modelo SARIMAX

6.1 Definición y motivación

El modelo **SARIMAX** (Seasonal ARIMA with eXogenous variables) extiende SARIMA incorporando un vector de variables explicativas $\mathbf{x}_t$ que aportan información causal o predictiva:

$$\Phi_p(L) \tilde{\Phi}_P(L^s) \nabla^d \nabla_s^D Y_t = \mathbf{x}_t^\top \boldsymbol{\beta} + \Theta_q(L) \tilde{\Theta}_Q(L^s) \varepsilon_t$$

Las variables exógenas $\mathbf{x}_t$ no son modeladas por el sistema (son determinísticas o provienen de otro modelo), pero condicionan el nivel de Y_t más allá de su propia dinámica estacional.

6.2 Base de datos: Ventas de helados con variables exógenas

Table 7: Base de datos para modelo SARIMAX — Ventas de helados (2020–2021)

Fecha	Mes	Ventas Y_t	Temp. (X_{1t} , °C)	Precio (X_{2t} , \$)	$\ln(Y_t)$	Festivo (X_{3t})
2020-01	Enero	850	12	25	6.745	0
2020-02	Febrero	900	14	25	6.802	0
2020-03	Marzo	1 200	19	26	7.091	0
2020-04	Abril	1 500	24	26	7.313	1
2020-05	Mayo	2 100	30	27	7.650	0
2020-06	Junio	2 800	35	27	7.937	0
2020-07	Julio	3 200	38	28	8.071	1
2020-08	Agosto	3 100	37	28	8.039	0
2020-09	Septiembre	2 400	32	27	7.783	0
2020-10	Octubre	1 600	25	26	7.378	0
2020-11	Noviembre	1 000	16	25	6.908	0
2020-12	Diciembre	870	13	25	6.768	1
2021-01	Enero	920	13	25	6.824	0
2021-02	Febrero	980	15	26	6.888	0
2021-03	Marzo	1 350	21	26	7.208	0
2021-04	Abril	1 680	26	27	7.427	1
2021-05	Mayo	2 250	31	27	7.719	0
2021-06	Junio	2 950	36	28	7.990	0
2021-07	Julio	3 400	39	29	8.131	1
2021-08	Agosto	3 280	38	28	8.096	0
2021-09	Septiembre	2 600	33	27	7.863	0
2021-10	Octubre	1 750	26	26	7.467	0
2021-11	Noviembre	1 100	17	25	7.003	0
2021-12	Diciembre	950	14	25	6.856	1

Y_t : ventas en unidades. X_{3t} : indicador binario de mes con días festivos significativos.

6.3 Figura: Estacionalidad de ventas de helados




Figure 3: Las ventas de helados exhiben un patrón estacional claro ($s = 12$) fuertemente correlacionado con la temperatura. Este es el argumento para incluir la temperatura como variable exógena en el modelo SARIMAX(1, 1, 1)(1, 1, 0)₁₂.

6.4 ¿Cuándo usar SARIMAX vs. SARIMA?

Table 8: Comparación SARIMA vs. SARIMAX

Aspecto	SARIMA	SARIMAX
Variables	Sólo Y_t (univariado)	$Y_t +$ regresores $\mathbf{x}_t$
Causalidad	No requiere teoría causal	Requiere justificación económica/financiera
Pronóstico	Sólo necesita historia de Y	Necesita pronóstico de $\mathbf{x}_{t+h}$ también
Ventaja	Simple, robusto	Menor varianza del error si $\mathbf{x}_t$ es relevante
Uso típico	Tasas de interés, índices	Ventas con precios, demanda con clima

7 Proceso de Modelación: Metodología Box-Jenkins

La metodología de Box y Jenkins para identificar, estimar y validar un modelo SARIMA sigue cuatro etapas:

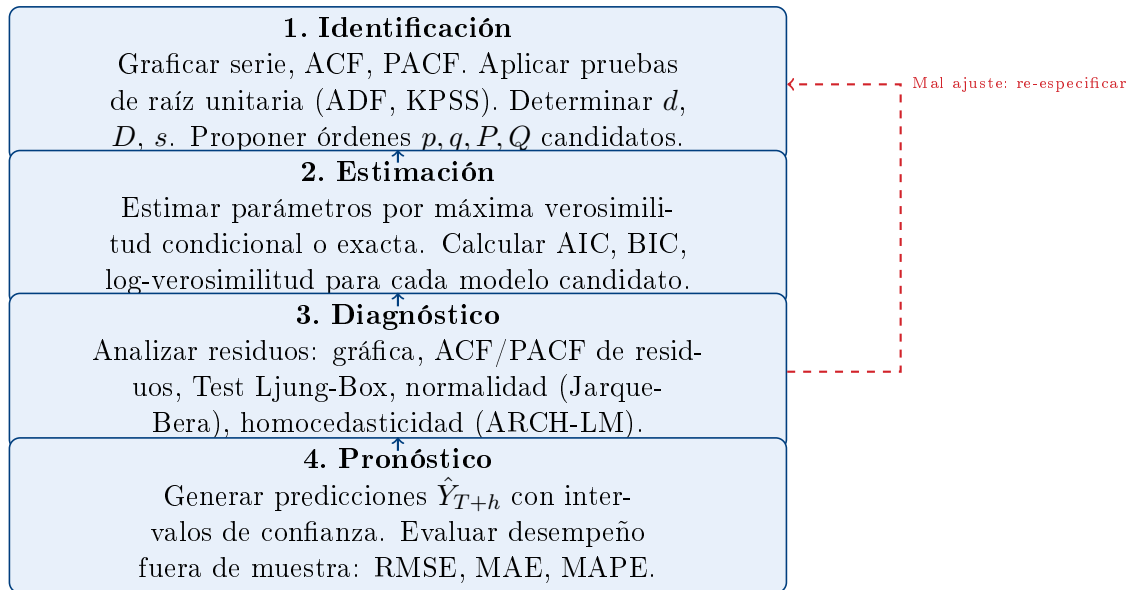


Figure 4: Metodología Box-Jenkins para la construcción de modelos SARIMA/SARIMAX. Si el diagnóstico detecta residuos con estructura, se regresa a la etapa de identificación.

8 Resumen de Criterios y Fórmulas Clave

Table 9: Guía rápida de referencia — Modelos (S)ARIMA y SARIMAX

Elemento	Fórmula / Descripción	Uso
Modelo SARIMA	$\Phi(L)\tilde{\Phi}(L^s)\nabla^d\nabla_s^D Y_t = \Theta(L)\tilde{\Theta}(L^s)\varepsilon_t$	= Ecuación general del proceso
Diferenciación	$\nabla Y_t = Y_t - Y_{t-1}, \quad \nabla_s Y_t = Y_t - Y_{t-s}$	Eliminar tendencia y estacionalidad
Parsimonia	$p + d + q + P + D + Q \leq C$	Evitar sobreajuste
AIC	$-2\hat{\ell} + 2k$	Selección de modelos
BIC	$-2\hat{\ell} + k \ln(n)$	Selección parsimoniosa
Ljung-Box	$Q = n(n+2) \sum_{k=1}^h \hat{\rho}_k^2 / (n-k)$	Diagnóstico de residuos
SARIMAX	$\Phi(L)\tilde{\Phi}(L^s)\nabla^d\nabla_s^D Y_t = \mathbf{x}_t^\top \boldsymbol{\beta} + \Theta(L)\tilde{\Theta}(L^s)\varepsilon_t$	Incluir variables externas

9 Conclusiones

Los modelos SARIMA y SARIMAX constituyen herramientas fundamentales en el análisis de series de tiempo para finanzas cuantitativas. La correcta identificación de

los órdenes $(p, d, q)(P, D, Q)_s$ mediante las funciones ACF y PACF, combinada con el principio de parsimonia y la evaluación sistemática con criterios AIC/BIC y el test de Ljung-Box, permite construir modelos que capturan tanto la dinámica temporal como la estructura estacional de variables financieras y económicas.

La extensión al modelo SARIMAX resulta especialmente valiosa cuando se dispone de variables exógenas con poder explicativo, como precios, indicadores macroeconómicos o variables climáticas, siempre que se garantice la disponibilidad de pronósticos de dichas variables para el horizonte de interés.

References

- [1] Box, G.E.P. y Jenkins, G.M. (1976). *Time Series Analysis: Forecasting and Control*. Holden-Day, San Francisco.
- [2] Hamilton, J.D. (1994). *Time Series Analysis*. Princeton University Press.
- [3] Shumway, R.H. y Stoffer, D.S. (2017). *Time Series Analysis and Its Applications*. Springer.
- [4] Hyndman, R.J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3a ed. OTexts. <https://otexts.com/fpp3/>
- [5] Brockwell, P.J. y Davis, R.A. (2016). *Introduction to Time Series and Forecasting*. Springer.